

Построение пайплайнов данных

Аналитика для инженеров: от бизнес-задачи к требованиям данных

Дмитрий Малахов

Максим Новосельцев

30 января 2026 года

Проблема: Разрыв между бизнесом и инженерами

Бизнес говорит: "Нужно повысить конверсию"

Инженер слышит: "Нужно собрать больше данных"

Результат: Гора данных, ноль инсайтов

Корень проблемы:

1. Бизнес формулирует цели, а не требования к данным
2. Инженеры фокусируются на технологиях, а не на бизнес-ценности
3. Нет общего языка для перевода бизнес-задач в требования к данным

Решение: Data Product Thinking

Data Product — это не просто данные, а:

Продукт, который использует данные для создания измеримой бизнес-ценности для конкретных пользователей

Примеры Data Products:

- Рекомендательная система
- Система мониторинга качества
- Платформа A/B тестирования
- Система предсказания оттока

Общий признак: Есть пользователи, есть ценность, есть измеримые метрики

Декомпозиция бизнес-задачи

Техника: "Дерево декомпозиции"

Бизнес-задача: "Увеличить удержание клиентов на 15%"

| — Гипотеза 1: "Клиенты уходят после плохого сервиса"

| | — Требование к данным: "Нужны данные о обращениях в поддержку"

| — Гипотеза 2: "Клиенты уходят из-за высокой цены"

| | — Требование к данным: "Нужны данные о реакции на изменения цен"

| — Гипотеза 3: "Клиенты уходят к конкурентам"

 | — Требование к данным: "Нужны сравнительные данные по рынку"

Правило: Каждая бизнес-гипотеза → конкретные требования к данным

User Stories для данных

Формат:

Как [роль пользователя]

Я хочу [получить информацию/инсайт]

Чтобы [принять решение/получить ценность]

Примеры:

Как менеджер по продукту, я хочу видеть метрики вовлечённости пользователей, чтобы понимать, какие фичи работают

Как аналитик, я хочу получать очищенные данные о транзакциях, чтобы строить отчёты без предобработки

Ключевое отличие от обычных User Stories: Акцент на информации, а не на функциональности

Data Product Canvas

1. Vision & Goals → *ЗАЧЕМ существует этот Data Product?*

2. Constraints → *Какие ограничения нужно учитывать?*

3. Users & Stories → *Кто пользуется и какие у них задачи?*

4. Inputs & Sources → *Откуда берутся данные?*

5. Outputs & Schema → *Что получаем на выходе?*

6. Quality & SLA → *Какие гарантии качества?*

7. Infrastructure → *Как технически реализовать?*

Единый инструмент для бизнеса, аналитиков и инженеров

Data Product Canvas: Vision & Goals

Vision (Видение):

- Какая фундаментальная проблема решается?
- Какой мир станет лучше?
- Пример: "Честная и прозрачная система оценивания знаний"

Goals (Цели):

- Измеримые метрики успеха
- Что конкретно улучшится?
- Пример: "90% пользователей понимают, как рассчитывается их оценка"

Ошибка: Путать Vision с техническими требованиями

Data Product Canvas: Constraints

Типы ограничений:

- **Ресурсные:** Время, бюджет, команда
- **Технические:** Существующая инфраструктура
- **Бизнес-ограничения:** Правила компании, законы
- **Данные:** Качество и доступность данных

Ограничения определяют ВОЗМОЖНОЕ, а не ЖЕЛАЕМОЕ

Data Product Canvas: Users & Stories

Типичные роли:

- **Бизнес-пользователи:** Принимают решения
- **Аналитики:** Исследуют данные
- **Операторы:** Используют данные в ежедневной работе
- **Системы:** Потребляют данные автоматически

Правило: Для каждой роли — хотя бы одна User Story

Data Product Canvas: Inputs & Sources

Источники данных:

- **ПЕРВИЧНЫЕ (сырые):** Логи приложений, Транзакционные БД, Внешние API
- **ВТОРИЧНЫЕ (обработанные):** Data Lake/Warehouse, Кэш-вычисления

Требования к источникам:

- Доступность (uptime)
- Своевременность (latency)
- Формат и структура

Data Product Canvas: Outputs & Schema

Принципы проектирования схемы:

1. **Отражать доменную логику:** Поля должны иметь бизнес-смысл
2. **Минимальная достаточность:** Только необходимые данные
3. **Гибкость:** Возможность эволюционировать
4. **Производительность:** Оптимизация под сценарии использования

Data Product Canvas: Quality

Метрики качества данных:

1. **Accuracy (Точность):** Процент ошибок
2. **Completeness (Полнота):** Процент заполненных полей
3. **Timeliness (Своевременность):** Задержка поступления данных
4. **Consistency (Согласованность):** Единые форматы и справочники
5. **Validity (Валидность):** Соответствие бизнес-правилам

Data Product Canvas: SLA

SLA (Service Level Agreement) — это договор о качестве

Формат:

Метрика [X] должна иметь значение [Y]

в [Z]% случаев

в течение периода [T]

Примеры:

"Данные о транзакциях должны быть доступны в течение 5 минут в 99.9% случаев"

"Отчёт за предыдущий день должен быть готов к 9:00 утра в 95% рабочих дней"

Важно: SLA должны быть измеримыми и реалистичными

Data Product Canvas: Infrastructure & Pipeline

Компоненты пайплайна:

1. Ingestion (приём) → Как данные поступают?
2. Storage (хранение) → Где хранятся?
3. Processing (обработка) → Как обрабатываются?
4. Serving (обслуживание) → Как предоставляются?

Выбор технологий должен следовать из:

- Требований к данным (SLA, объёмы, частота)
- Ограничений (бюджет, экспертиза)
- Существующей инфраструктуры

Практический алгоритм работы

Шаг 1: Собрать бизнес-задачи и декомпозировать их

Шаг 2: Написать User Stories для каждой роли

Шаг 3: Заполнить Data Product Canvas

Шаг 4: Согласовать SLA с бизнесом

Шаг 5: Спроектировать схему и пайплайн

Шаг 6: Реализовать и мониторить качество

Вопросы для самопроверки

- Понятно ли, какую бизнес-ценность создаёт Data Product?
- Есть ли User Story для каждого типа пользователей?
- Реалистичны ли SLA?
- Учтены ли ограничения?

Типичные ошибки и как их избежать

Ошибка 1: Начинать с технологий

Решение: Начинать с бизнес-задач

Ошибка 2: Неформализованные требования

Решение: Использовать Data Product Canvas

Ошибка 3: Игнорирование ограничений

Решение: Явно выписывать Constraints

Ошибка 4: SLA без измеримости

Решение: Определять SLI перед SLA

Ключевые компетенции инженера

Технические:

- Понимание систем данных (ETL/ELT, streaming, batch)
- Умение проектировать схемы
- Знание инструментов мониторинга

Бизнес-компетенции:

- Умение задавать правильные вопросы
- Перевод бизнес-задач в требования
- Коммуникация с нетехническими специалистами

Мягкие навыки:

- Системное мышление
- Внимание к деталям
- Умение работать с неопределённостью

Data Product Canvas для системы оценки студентов

Vision:

Единый источник истины о прогрессе студентов, доступный и понятный всем участникам образовательного процесса, без сложных технологий.

Goals:

- 100% доступность данных о прогрессе для преподавателя и студентов
- 100% консистентность итоговой оценки
- 100% прозрачность итоговой оценки и доступ к истории изменений

Data Product Canvas для системы оценки студентов

Constraints:

- Масштаб: 37 студентов $\times$ (14 ДЗ + 1 проект + 1 экзамен) = ~600 ячеек ручного ввода
- Обновление: Ручной ввод статусов преподавателем — человеческий фактор, задержки
- ДЗ должно быть получено преподавателем до соответствующего семинара
- Если студент защитил ДЗ на семинаре, преподаватель фиксирует информацию об этом (оценка не может быть пересмотрена на экзамене)
- Оценка за каждое ДЗ ставится 0 или 1
- Оценки КР_1 и Экзамен могут принимать дробное значение от 0 до 1
- Итоговая оценка за курс: $0.04 * (\text{ДЗ_1} + \text{ДЗ_2} + \text{ДЗ_3} + \text{ДЗ_4} + \text{ДЗ_5} + \text{ДЗ_6} + \text{ДЗ_7} + \text{ДЗ_8} + \text{ДЗ_9} + \text{ДЗ_10} + \text{ДЗ_11} + \text{ДЗ_12} + \text{ДЗ_13} + \text{ДЗ_14}) + 0.22 * \text{КР_1} + 0.22 * \text{Экзамен}$

Data Product Canvas для системы оценки студентов

Users & Stories :

- **Story S1:** "Как студент, я хочу открыть таблицу и сразу увидеть в своей строке статусы всех 14 ДЗ, чтобы понимать, что я сдал, а что нет"
- **Story S1:** "Как студент, я хочу открыть таблицу и сразу увидеть максимальный балл, на который я могу рассчитывать"
- **Story P1:** "Как преподаватель, я хочу одним взглядом увидеть, у кого из студентов проблемы с дедлайнами "
- **Story P2:** "Как преподаватель на экзамене, я хочу открыть строку студента и сразу увидеть, по каким темам были проблемы "
- **Story P3:** "Как преподаватель после экзамена, я хочу получить автоматический расчёт итоговой оценки"

Data Product Canvas для системы оценки студентов

Inputs & Sources (Ручной ввод):

- **Преподаватель:** проставляет оценки и комментарии для каждого студента
- **Студенты:** только просмотр, НЕ редактирование

Outputs & Schema (Один лист Google Sheet со столбцами): ФИО студента

- **(14 столбцов) Для каждого ДЗ:** 0 если не прислал в срок или не прошел проверку иначе 1
- **Проект:** 1 если сдал проект на высший балл или защиты еще не было
- **Экзамен:** 1 если сдал экзамен на высший балл или экзамена еще не было
- **Итог:** сумма всех оценок или оценка за пересдачу
- **Комментарий:** содержит информацию о сданных ДЗ

Data Product Canvas для системы оценки студентов

Quality & SLA:

- Время на обновление таблицы (В течение 48 часов после изменения статуса)
- Время на исправление ошибок в данных (В течение 48 часов после обнаружения)

Инфраструктура:

Единственный компонент: Google Sheet с настройками доступа

Data Product Canvas для системы оценки студентов

Еженедельный пайплайн:

В течение недели студенты присылают ДЗ преподавателю

→ Преподаватель обнуляет оценки за ДЗ не приславшим вовремя студентам

В течение семинара студенты защищают ДЗ

→ Преподаватель ставит пометку о защите

Студенты проверяют свои статусы

→ Вопросы к преподавателю

→ Преподаватель корректирует ошибку

Data Product Canvas для системы оценки студентов

Пайплайн защиты проекта:

Преподаватель открывает таблицу, анализирует строку студента:

→ На основании разметки формулирует вопросы к коду проекта

→ После ответов поле Проект уточняется

Пайплайн экзамена:

Преподаватель открывает таблицу, анализирует строку студента:

→ На основании разметки формулирует вопросы по незащищенным ДЗ и в целом по курсу

→ После ответов поле Экзамен уточняется, оценки по части ДЗ могут быть обнулены

А что вообще такое бизнес-требования?

- Какая должна быть степень детализации продукта?
- Какие ограничения реально можно считать таковыми?
- А если ограничений нет, нужно ли их задать и как это сделать?
- Где вообще заканчивается зона ответственности инженера данных или архитектора?

Истинные ограничения могли бы быть такими

- **A1 (Полнота):** Все 14 тем курса обязательны для освоения и проработки.
- **A2 (Верификация):** Без синхронных вопросов к студенту нельзя установить факт самостоятельного выполнения работы.
- **A3 (Коллективность):** Разбор типовых ошибок в группе более эффективен, чем индивидуальные проверки, есть 15 семинаров $\times$ 90 минут = 1350 минут доступного синхронного времени на 37 студентов.
- **A4 (Разносторонность):** Количество лекций и семинаров одинаково
- **A5 (Мотивация):** Успешное выполнение 2/3 заданий курса, не позволит студенту остановиться на накоплении 35% (минимально допустимой оценки)

Тут можно сделать выводы

- **A1 → P1:** Каждая тема требует проверки, нужно 14 заданий, проверка задания занимает примерно 10 минут
- **P1, A1, A2, A3 → P2:**

Проверка всех заданий невозможна, т.к. требует $10 * 37 * 14 = 5180$ минут (x4)

- **P2 → P3:** Требуется выборочная проверка из расчета 10 минут на человека (9 человек на тему, вероятность ответа 25%)
- **P3 → P4:** Проверка оставшихся 75% заданий должна быть в конце курса на экзамене

(иначе пришлось бы зачесть всем задание, не сделавший ни одно из них мог бы получить 75% оценки)

Тут можно сделать выводы

- **A5, P3 → P5:** Дедлайн по заданию до следующего семинара, а оценка за задание до 4% ($4\% * ([1/3 * 14]) = 36\%$, даже если студента проверяют каждый семинар он наберет не более 36% за 2/3 семинаров).

(иначе не все пришлют задания и их может не хватить для разбора на семинаре, потеряем часть времени впустую и не успеем в будущем разобрать целевое количество заданий)

- **A4, P5 → P6:**

Теория (Экзамен) и практика (Проект) оцениваются одинаково по $22\% = (100\% - 14 * 4\%) / 2$

- **P6, P4 → A1**

Часть заданий не будут проверены (каким бы долгим ни был экзамен), но какие именно заранее неизвестно, придется повторить перед экзаменом все, даже чтобы получить минимально необходимые 35% (а если они уже набраны, то студент на этом не должен остановиться согласно A5).

Итоги:

А могли бы быть и такие требования, которые стали следствиями:

- **Честность:** Оценка отражает реальные знания и умения студента в том числе в конце курса
- **Рефлексия:** Повторное осмысления материала после его первичного изучения, а также разбор сделанных ранее заданий приводят к более устойчивому обучению
- **Регулярность:** Работа над курсом происходит в течении всего семестра
- **Мотивация:** Активность студента поощряется, доверие к нему повышается, итоговая аттестация проходит проще и предсказуемей

Измерили все кроме доверия...

Итоги:

- Доверие бесценно
- Проактивность - ключ к успеху

Домашнее задание

Поставьте задачу на создание объективной системы оценки преподавателей студентами и руководством университета.

Система оценки должна быть выведена из базовых принципов и максимально прозрачна для преподавателя (чтобы он понимал, за что ему срезали оценку).

1. Сформулируйте 3 User Stories для данных
2. Набросайте Data Product Canvas
3. Определите хотя бы 2 ключевых метрики качества и хотя бы по одному SLA к каждой из них