

Построение пайплайнов данных

Kafka

Малахов Дмитрий Андреевич
Новосельцев Максим Сергеевич

23 января 2026 года

Основные компоненты Kafka

- Сообщение (message)
- Производитель (producer)
- Потребитель (consumer)
- Топик (topic)
- Журнал коммитов (commit log)
- Партиция (partition)
- Брокер (broker)
- Сегмент (segment)
- Группа потребителей (consumer group)

Основные параметры производителя

- Топик, в который будут записаны данные;
- партицию, в которую будут записаны сообщения, имеющие одинаковый ключ;
- срок хранения сообщений в Kafka;
- необходимое сжатие;
- необходимый уровень подтверждения о записи сообщения в партицию и ее реплик;
- коэффициент репликации партиций.


Основные параметры потребителя

- group_id для каждой из групп потребителя, который определяет, откуда группа будет читать сообщения;
- максимальное время ожидания клиентом ответа на запрос;
- необходимый уровень подтверждения доставки сообщений


Основные параметры сообщения

- данные (data);
- ключ (key) для определения записи сообщений в одну и ту же партицию при необходимости
- отметка времени (timestamp)


Последовательность записи и чтения




Репликация




Точка-точка



Публикация-подписка




Политика очищения журналов



Удаление (delete)

log.retention.hours

log.retention.bytes





Сжатие

log.cleaner.min.cleanable.ratio


log.cleaner.min.compaction.lag.ms

log.cleaner.max.compaction.lag.ms




Сжатие



Сжатие




Сжатие




Настройка топика

```
/usr/lib/kafka/bin/kafka-topics.sh \  
--create --topic new-topic1 \  
--config cleanup.policy=delete \  
--config retention.ms=10000 \  
--config retention.bytes=128000 \  
--bootstrap-server localhost:9092
```



At most once



At least once




Транзакции



Фактор репликации в Kafka


default.replication.factor




Синхронизация реплик

`replica.lag.time.max.ms`


`min.insync.replicas`



KRaft



Kafka Tiered Storage



- **Как работает чтение в Kafka?**

- Как работает чтение в Kafka?
- Что такое Offset и зачем он нужен?

- Как работает чтение в Kafka?
- Что такое Offset и зачем он нужен?
- Как гарантировать порядок обработки сообщений?

- Как работает чтение в Kafka?
- Что такое Offset и зачем он нужен?
- Как гарантировать порядок обработки сообщений?
- Когда удаляются данные в Kafka?

- Как работает чтение в Kafka?
- Что такое Offset и зачем он нужен?
- Как гарантировать порядок обработки сообщений?
- Когда удаляются данные в Kafka?
- Когда использовать Kafka, а когда RabbitMQ / очереди?

Домашнее задание

Вы — архитектор данных в компании Консультант Плюс. Вам нужно предложить, как организовать пайплайн обработки документов на Kafka.

- Опишите, на какие топики вы разобьёте потоки данных (законы, судебные решения, редакции документов и т.д.), сколько партиций сделаете и какие ключи будете использовать
- Объясните, какие политики хранения вы выберете
- Продумайте гарантии доставки
- Подумайте, какие группы потребителей будут в системе

Оформите все в виде схемы и описания к ней