

Построение пайплайнов данных

Распределённые SQL-движки

Малахов Дмитрий Андреевич

Новосельцев Максим Сергеевич

23 января 2026 года

Немного про старичка Hive

Apache Hive — это система для работы с Big Data, которая выполняет SQL-подобные запросы. Ее основная задача — упростить обработку и анализ неструктурированных данных, а также анализировать данные из внешних хранилищ.



В Apache Hive существует два основных типа таблиц:

- Внутренние (managed tables)
- Внешние (external tables)

Hive взаимодействует со следующими компонентами:

- HDFS, Metastore и другими хранилищами;
- YARN (управляет ресурсами кластера);
- движками выполнения запросов (MapReduce, Tez, Spark).

Разница SQL и HiveQL

- Классический SQL нужен для работы с реляционными данными
- Вместо индексов для ускорения в Hive используется партиционирование
- Помимо стандартных, HiveQL умеет обрабатывать сложные типы данных: массивы, словари (map), вложенные данные (struct) и объединения (union)
- Hive же рассчитан на одноразовую загрузку данных
- Не предназначен для обработки данных в реальном времени

Разница SQL и HiveQL

- Классический SQL нужен для работы с реляционными данными
- Вместо индексов для ускорения в Hive используется партиционирование
- Помимо стандартных, HiveQL умеет обрабатывать сложные типы данных: массивы, словари (map), вложенные данные (struct) и объединения (union)
- Hive же рассчитан на одноразовую загрузку данных
- Не предназначен для обработки данных в реальном времени


Что такое Trino

- это движок SQL-запросов с открытым исходным кодом, используемый для параллельной обработки данных, распределенных по хранилищам разного типа, таких как объектные хранилища (S3), базы данных и файловые системы.




Концепции

- Коннекторы
- Каталог
- Менеджер каталогов
- Схема
- Выражение (statement)
- Этап (stage)
- Задача (task)
- Сплит (split)



Компоненты



А может StarRocks



Сходства StarRocks и Trino

- Масштабно-параллельная (MPP) архитектура
- Оптимизатор на основе стоимости
- Конвейерная (pipeline) модель выполнения
- Поддержка ANSI SQL

Отличия StarRocks и Trino

- Векторизованный движок запросов
- Материализованные представления
- Система кэширования
- Производительность JOIN
- Высокая доступность (HA)
- Источники данных и открытые форматы таблиц

Домашнее задание

Проведите сравнительный анализ распределенных SQL-движков (минимум: Trino и StarRocks)

В отчете обязательно раскройте 4 пункта:

1. Бенчмарки - свои тесты и/или ссылки на источники со своими комментариями
2. Ключевые различия
3. Анализ рисков внедрения
4. Итоговое решение

Транзакции (с прошлой лекции)

